Universidad Nacional del Nordeste





Facultad de Ciencias Exactas y Naturales y Agrimensura Licenciatura en Sistemas de Información Base de datos I Año: 2023

Índices columnares SQL

Comisión 1 grupo 5

Alumno: Bournisent, Matias

L.U. N°: 50.434

D.N.I. N°: 39.126.075

Alumno: Comba, Carlos Alfredo

L.U. N°: 44.055

D.N.I. N°: 32.335.478

Alumno: Ramirez Gonzalo Daniel

L.U. N°: 56.838

D.N.I. N°: 44.543.439

Alumno: Zini, Franco Joaquin

L.U. N°: 50.717

D.N.I. N°: 40.049.028

Índice

Capítulo I: Introducción	3
Capítulo II: Marco teórico	4
Capítulo III: Metodología	7
Proceso de trabajo	7
Organización del grupo	7
Herramientas	7
Procedimientos de Recopilación de Datos	8
Capítulo IV: Desarrollo/Resultados	9
Introducción	9
Desarrollo	9
Resultados de las pruebas	11
Capítulo V: Conclusión	16
Capítulo VI: Bibliografía	17

Capítulo I: Introducción

En el ámbito de la materia Base de Datos I, se nos asignó la tarea de investigar y experimentar con un componente fundamental del diseño de bases de datos: **los índices columnares**. El enfoque se centra en analizar cómo los índices impactan en el rendimiento del sistema, utilizando un caso de estudio concreto.

Partiendo de un modelo de base de datos proporcionado por la cátedra, llamado "base_consorcio", nuestra tarea es duplicar la tabla 'gasto', creando así una nueva tabla denominada 'gastoNew'. La clave de nuestro estudio es la implementación de índices columnares en esta nueva tabla, lo que nos permitió investigar cómo estos índices aceleran la recuperación de datos.

Ambas tablas se cargaron con un millón de registros para crear un escenario realista de carga de trabajo. Nuestro objetivo es evaluar y comparar las diferencias de rendimiento entre las búsquedas realizadas en una tabla con índices columnares ('gastoNew') y una sin ellos ('gasto'), para entender la mejora que ofrecen estos índices.

Este informe proporcionará detalles de nuestra metodología, incluyendo los fundamentos teóricos de los índices columnares, los scripts utilizados para modificar las tablas y realizar las inserciones, así como los scripts de búsqueda. Además, se detalla el entorno técnico en el que se llevaron a cabo las pruebas, incluyendo el motor y gestor de la base de datos utilizados, así como las especificaciones de las máquinas que alojan nuestras pruebas.

Los resultados de nuestras pruebas consisten en los tiempos de respuestas de cada consulta, así como gráficas comparativas que permiten ver la mejora de tiempo utilizando los índices columnares. Estos datos permiten cuantificar el impacto de los índices columnares en el rendimiento del sistema.

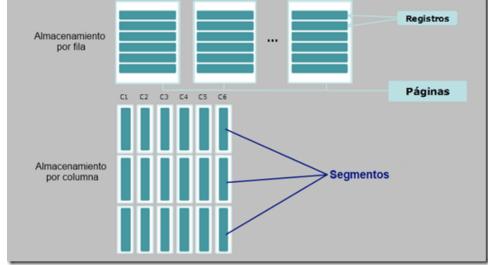
Capítulo II: Marco teórico

En la gestión de bases de datos, el uso de índices columnares optimiza el rendimiento. Son estructuras de datos especializadas que permiten una recuperación eficiente de información en grandes conjuntos de datos. En lugar de buscar a través de todas las filas de una tabla, los índices columnares almacenan y ordenan los valores de una columna específica, actuando como rutas de acceso rápidas hacia los datos que los usuarios buscan. Markus Winand nos dice que "Los índices columnares son un tipo de índice que almacena los datos en columnas, en lugar de filas. Este enfoque de almacenamiento permite que el motor de base de datos acceda a los datos de manera más eficiente, lo que puede traducirse en un rendimiento de las consultas más rápido." (SQL Performance Explained" por Markus Winand, pag. 102)

Siguiendo con los conceptos de Markus Winand nos explica también que "Los índices columnares son particularmente útiles para consultas que requieren operaciones de agrupación, ordenación o filtros complejos. En estas situaciones, los índices columnares pueden proporcionar un rendimiento de las consultas significativamente mejor que los índices tradicionales." (SQL Performance Explained" por Markus Winand, pag. 102)

En el mismo libro encontramos un concepto más complejo sobre las teorías de "Los índices columnares que utilizan técnicas de compresión para acelerar las consultas. Estas técnicas permiten al motor de base de datos acceder a los datos de manera más eficiente."... "Las técnicas de compresión de índices columnares se pueden utilizar para reducir el tamaño de los datos almacenados en el índice. Esto puede mejorar el rendimiento de las consultas, ya que el motor de base de datos no tiene que leer tantos datos para encontrar los registros que coinciden con la consulta." ((Fundamentos de Base de Datos" de Korth H. y Silberschatz A. pág. 381-382)

El almacenamiento columnar se realiza de la siguiente forma: Almacenamiento por fila



- En primer lugar, consideremos el enfoque tradicional de almacenamiento por filas, donde los datos se organizan en páginas de datos y se almacenan fila por fila en estas páginas.
- En contraste, en el almacenamiento por columnas, se adopta un enfoque diferente. Aquí, los valores de cada columna se separan y almacenan en segmentos individuales. Estos segmentos contienen los datos de las columnas y se someten a compresión utilizando la tecnología VertiPaq(Tecnología de compresión de datos).

Cuando se crea un índice columnar para una columna específica, la base de datos organiza los valores de esa columna en una estructura de datos optimizada:

- Árboles B: Los índices columnares basados en árboles B son estructuras de datos de tipo árbol que permiten búsquedas eficientes, inserciones y eliminaciones. Estos árboles están diseñados para minimizar la altura del árbol, lo que vuelve la búsqueda más rápida.
- Árboles B+: Son una variante de los árboles B que mejora aún más la eficiencia en las operaciones de búsqueda. Los nodos internos de un árbol B+ contienen solo claves para la navegación, lo que aumenta la capacidad de almacenamiento de las claves y mejora la velocidad de búsqueda.
- Estructuras de Bitmap: Los índices columnares basados en estructuras de bitmap son eficaces para columnas que tienen un número limitado de valores únicos (por ejemplo, género o estado civil). Cada valor único se asigna a un conjunto de bits, y las operaciones de búsqueda implican operaciones lógicas en estos conjuntos de bits, lo que permite búsquedas rápidas y eficientes.
- Índices Hash: Los índices hash se basan en funciones hash que asignan valores de columna a ubicaciones específicas en una estructura de datos hash. Esto permite búsquedas rápidas cuando se conoce el valor exacto de la columna. Sin embargo, los índices hash no son tan eficientes para operaciones como el rango o las comparaciones de patrones.
- Árboles Trie: Estos árboles son útiles para índices columnares en datos de texto o cadenas. Los árboles Trie almacenan información de texto de manera jerárquica, lo que facilita la búsqueda y comparación de palabras o patrones de texto.

La elección de la estructura asociada a un índice columnar depende del tipo de datos en la columna y del tipo de operaciones que se realizarán con esa columna (por ejemplo, búsquedas exactas, búsquedas de rango, etc.). Cada estructura tiene sus ventajas y desventajas, por lo que se selecciona según los requisitos específicos de la aplicación. El motor de base de datos toma la decisión de qué

estructura de índice utilizar. Los DBMS están diseñados para ser sistemas inteligentes y autónomos que optimizan el rendimiento de las consultas y operaciones en función de la estructura de los datos y el tipo de consultas que se realizan.

Ventajas de los índices columnares:

Los índices columnares ofrecen una serie de ventajas sobre los índices tradicionales, entre las que se incluyen:

- Mejor rendimiento para consultas que requieren la comparación de valores en una sola columna.
- Reducción del uso de memoria del servidor.
- Mejor compresión de datos.
- Reducción de la fragmentación de datos.

Los índices columnares no son ideales para todos los entornos, por ejemplo estos no son ideales en el ámbito de procesamiento de transacciones en línea (OLTP) donde se realizan operaciones de inserción, actualización y eliminación con alta frecuencia. Están orientados para las situaciones en las que las operaciones de lectura son más frecuentes comparadas a las de escritura. Otra desventaja que presentan Los índices columnares es que pueden requerir más espacio de almacenamiento que los índices tradicionales basados en filas, especialmente durante el proceso de carga de datos, debido a esto el costo de almacenamiento puede incrementarse enormemente, también el uso de índices columnares puede requerir recursos adicionales del sistema, como CPU y memoria, para su procesamiento. En entornos con recursos limitados, esto puede ser un factor a considerar.

Los índices columnares se utilizan a menudo en situaciones donde se requiere un alto rendimiento para consultas analíticas y agregaciones en bases de datos que manejan grandes volúmenes de datos, las más populares son:

- Análisis de datos (OLAP)
- Data warehousing:
- Business intelligence
- Big data

Capítulo III: Metodología

Proceso de trabajo

Sobre la base del modelo que entregó la cátedra. La estructura de base de datos y dos lotes de carga.

Donde se ejecuta:

- 1. ModeloDatos_Consorcio.sql: este script crea la base de datos y sus tablas.
- 2. BDI_loteDatosConsorcios.sql: permite cargar los datos de provincias, localidad, zona, conserje, administracion, consorcio, tipogasto, gasto.
- 3. BDI_tabla_inmueble_completo.sql: crea y carga la tabla inmueble.
- columnstore_index_script.sq: crea la tabla gastonew, crea los índice columnares, se insertan 1 millón de registros, y se carga la tabla gasto con los registros faltantes para llegar al millón y poder hacer las pruebas comparativas.
- 5. script busqueda.sql: Contiene el conjunto de pruebas.

Organización del grupo

Mediante reuniones sincrónicas realizamos la manera en la cual abordamos el proyecto sobre índices columnares, como así también creamos el repositorio en github para que cada alumno interactúe con el contenido, aportando sus resultados, scripts y para reunir toda la información recopilada por cada miembro.

Cada estudiante ejecutará el script de busqueda.sql y anotará sus resultados en la tabla de referencia. El test ejecuta 5 pruebas de distintas operaciones sobre ambas tablas, registrando el tiempo de ejecución en cada una

Herramientas

Elementos comunes a todos:

 Script en Transact-SQL (Es el lenguaje utilizado para interactuar y gestionar bases de datos en el sistema de gestión de bases de datos Microsoft SQL Server.)

Elementos usados por Comba Carlos para las pruebas:

- Motor de base de datos SQL Server 2022 standard versión 16.0.1000.6
- SQL management Studio 19.1.56
- Máquina i7 11gen, 32 gb ram, 1tb ssd.

Elementos de prueba usado por Ramirez Gonzalo para las pruebas:

- Motor de base de datos SQL Server 2022
- SQL management Studio 19.1.56
- Equipo: Ryzen 3 3100, 16 gb de ram, Ssd 240GB.

Elementos de prueba usado Zini Franco para las pruebas:

- Motor de base de datos SQL Server 2022
- SQL management Studio 19.1.56
- Equipo: i5 12gen, 16 gb de ram, ssd 480gb.

.Elementos de prueba usado por Bournisent Matias para las pruebas:

- Motor de base de datos SQL Server 2022
- SQL management t Studio 19.1.56
- Equipo: Ryzen 5 5500u, 8gb de ram,ssd 256gb

Procedimientos de Recopilación de Datos

Para obtener la información que necesitábamos para nuestro proyecto, principalmente lo obtuvimos de fuentes de paginas webs (aclaradas en sección de bliblografias). En este proceso, hicimos lectura de documentos técnicos, exploramos tutoriales y recursos que encontramos en línea. Este enfoque nos ayudó a reunir una variedad de datos útiles y nos dio una buena base para llevar a cabo nuestro proyecto.

La información y conocimiento adquirido por cada alumno fue puesta en escena en las reuniones realizadas, para así poder nutrirnos todos sobre el tema en cuestión y la realización del proyecto.

Capítulo IV: Desarrollo/Resultados

Introducción

En esta sección, haremos foco en el análisis de las pruebas de rendimiento realizadas en consultas que involucran el uso de índices columnares en comparación con aquellas que no los utilizan. Nuestra principal misión es evaluar y presentar resultados concretos que permitan comprender el impacto de estos índices en términos de tiempo, costos y rendimiento. Las pruebas son realizadas en distintos escenarios para así comprobar el desempeño de los índices columnares en situaciones variadas. Estos escenarios pueden incluir consultas que involucran un gran volumen de datos, consultas de agregación, búsquedas de información y más. Esto nos permitirá obtener una visión completa de cómo los índices columnares se desempeñan en diversas circunstancias.

Desarrollo

1. El primer paso crucial en nuestro proyecto fue la creación de la nueva tabla "gastoNew". Para garantizar la coherencia y la continuidad de los datos con respecto a la tabla existente "gasto", se optó por replicar cuidadosamente su estructura. Para ello, identificamos cada columna en la tabla "gasto" junto con su tipo de dato correspondiente, lo que nos permitió diseñar la estructura de "gastoNew" de manera precisa y efectiva.

```
CREATE TABLE [dbo].[gastonew](
   [idgasto] [int] IDENTITY(1,1) NOT NULL,
   [idprovincia] [int] NULL,
   [idlocalidad] [int] NULL,
   [idconsorcio] [int] NULL,
   [periodo] [int] NULL,
   [fechapago] [datetime] NULL,
   [idtipogasto] [int] NULL,
   [importe] [decimal](8, 2) NULL,
   CONSTRAINT [PK_gastonew] PRIMARY KEY CLUSTERED ([idgasto] ASC),
   CONSTRAINT [FK_gasto_consorcio_new] FOREIGN KEY ([idprovincia], [idlocalidad], [idconsorcio])
   REFERENCES [dbo].[consorcio] ([idprovincia], [idlocalidad], [idconsorcio]),
   CONSTRAINT [FK_gasto_tipo_new] FOREIGN KEY ([idtipogasto])
   REFERENCES [dbo].[tipogasto] ([idtipogasto]))
```

2. Como segundo paso en nuestro proyecto, después de haber creado la tabla "gastoNew" basada en la estructura de la tabla "gasto", nos enfocamos en la creación del índice columnar. Diseñamos y creamos un índice columnar específico denominado "IX_GASTONEW_Columnar" en la tabla "gastoNew". Este índice se configuró para incluir columnas clave que son relevantes para las consultas financieras, como "idprovincia", "idlocalidad", "idconsorcio" etc. Cada una de estas columnas se almacenó y se indexó de manera

independiente lo que permitió una recuperación de datos más rápida y eficiente en comparación con los índices de filas tradicionales.

```
CREATE NONCLUSTERED COLUMNSTORE INDEX IX_GASTONEW_Columnar
ON dbo.GASTONEW
(
    idprovincia,
    idlocalidad,
    idconsorcio,
    periodo,
    fechapago,
    idtipogasto,
    importe
);
```

3. Después de haber creado la tabla "gastoNew" y el índice columnar, el tercer paso de nuestro proyecto involucró la generación de datos de prueba para llenar la tabla con información ficticia. Estos datos de prueba se utilizarían en nuestras pruebas de rendimiento y evaluación del índice columnar. Para facilitar la inserción de datos de prueba en la tabla, desactivamos temporalmente todas las restricciones de clave externa utilizando la sentencia SQL, Esta acción nos permitió insertar datos en la tabla sin preocuparnos por las restricciones de integridad referencial que normalmente se aplicarían.

```
ALTER TABLE dbo.gastonew NOCHECK CONSTRAINT ALL;

DECLARE @counter INT = 1;

WHILE @counter <= 1000000

BEGIN

INSERT INTO dbo.gastonew (idprovincia, idlocalidad, idconsorcio, periodo, fechapago, idtipogasto, importe)

VALUES (

-- Valores aleatorios para cada columna

CAST((RAND() * (5-1) + 1) AS INT), -- idprovincia (aleatorio entre 1 y 5)

CAST((RAND() * (5-1) + 1) AS INT), -- idlocalidad (aleatorio entre 1 y 5)

CAST((RAND() * (40-1) + 1) AS INT), -- periodo (aleatorio entre 1 y 400)

CAST((RAND() * (9-1) + 1) AS INT), -- periodo (aleatorio entre 1 y 9)

GETDATE(), -- fechapago (fecha y hora actual)

CAST((RAND() * (5-1) + 1) AS INT), -- idtipogasto (aleatorio entre 1 y 5)

CAST((RAND() * (400000-55000) + 55000) AS DECIMAL(8,2)) -- importe (aleatorio entre 50000 y 300000)

);

SET @counter = @counter + 1;

END;

-- Vuelve a habilitar las restricciones de clave externa

ALTER TABLE dbo.gastonew CHECK CONSTRAINT ALL;

GO
```

4. Como parte de nuestro enfoque en la comparación justa y precisa del impacto del índice columnar en las consultas, repetimos el proceso de generación de datos en la tabla "gasto". Esto nos permitió establecer una base de datos de pruebas similar en términos de volumen de datos y estructura de la tabla, lo que facilita la evaluación del rendimiento entre la tabla con índice columnar.

```
ALTER TABLE dbo.gasto NOCHECK CONSTRAINT ALL;
DECLARE @counter INT = 1;
WHILE @counter <= 992000
   INSERT INTO dbo.gasto (idprovincia, idlocalidad, idconsorcio, periodo, fechapago, idtipogasto, importe)
        -- Valores aleatorios para cada columna
       CAST((RAND() * (5-1) + 1) AS INT), -- idprovincia (aleatorio entre 1 y 5)
       CAST((RAND() * (5-1) + 1) AS INT), -- idlocalidad (aleatorio entre 1 y 5)
       CAST((RAND()*(40-1)+1) AS INT), -- idconsorcio (aleatorio entre 1 y 400)
       CAST((RAND() * (9-1) + 1) AS INT), -- periodo (aleatorio entre 1 y 9)
       GETDATE(), -- fechapago (fecha y hora actual)
       CAST((RAND() * (5-1) + 1) AS INT), -- idtipogasto (aleatorio entre 1 y 5)
       CAST((RAND() * (400000-55000) + 55000) AS DECIMAL(8,2)) -- importe (aleatorio entre 50000 y 300000)
   SET @counter = @counter + 1;
END:
-- Vuelve a habilitar las restricciones de clave externa
ALTER TABLE dbo.gasto CHECK CONSTRAINT ALL;
GO
```

5. Una vez que hemos completado los pasos anteriores, procedemos a ejecutar pruebas de consulta en las tablas "gastoNew" y "gasto". El objetivo de estas pruebas es comparar el tiempo de ejecucion de las consultas en ambas tablas para evaluar el impacto que tiene el índice columnar en el rendimiento de las operaciones.

Resultados de las pruebas

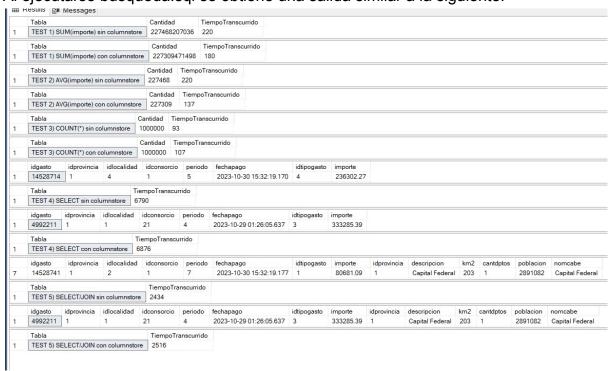
Después de ejecutar un conjunto de pruebas de consulta en las tablas "gastoNew" y "gasto", (Cuyas consultas se encuentran en el archivo busqueda.sql) hemos recopilado resultados significativos que nos permiten evaluar el impacto del índice columnar en el rendimiento de nuestras operaciones.

A Continuación cada alumno presenta la tabla de resultados de un total de 5 test, en donde se mide el tiempo de respuesta en milisegundos

Se ejecutaron los siguientes tests, con código adicional que mide el tiempo transcurrido, omitido aquí por brevedad, el código completo se encuentra en el repositorio en el archivo busqueda.sql:

```
--Test 1: Suma de la columna importe
 SELECT @ValorSinColumnstore = SUM(importe) FROM gasto;
 SELECT @ValorConColumnstore = SUM(importe) FROM gastonew;
 --Test 2: promedio de la columna importe
 SELECT @ValorSinColumnstore = AVG(importe) FROM gasto;
 SELECT @ValorConColumnstore = AVG(importe) FROM gastonew;
 --Test 3: Conteo de registros en cada tabla
 SELECT @ValorSinColumnstore = COUNT(*) FROM gasto WHERE idconsorcio <= 250;</pre>
 SELECT @ValorConColumnstore = COUNT(*) FROM gastonew WHERE idconsorcio <= 250;
 --Test 4: Select * en cada tabla
 SELECT * FROM gasto WHERE idconsorcio <= 250;
 SELECT * FROM gastonew WHERE idconsorcio <= 250;
 -- Test 5: Select con join
±SELECT gn.* , pro.* FROM gasto as gn
 join provincia as pro on gn.idprovincia = pro.idprovincia
 WHERE idconsorcio <= 250 and pro.idprovincia = 1
∃SELECT gn.* , pro.* FROM gastonew as gn
 join provincia as pro on gn.idprovincia = pro.idprovincia
WHERE idconsorcio <= 250 and pro.idprovincia = 1
```

Al ejecutarse busqueda.sgl se obtiene una salida similar a la siguiente:

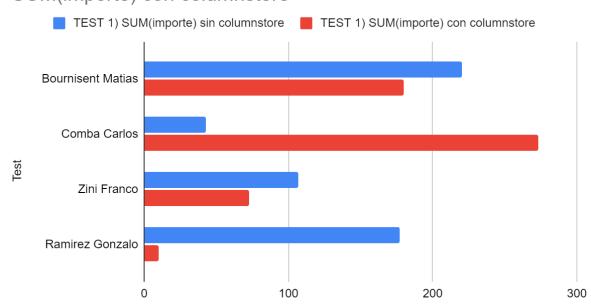


Los resultados de todos los integrantes fueron

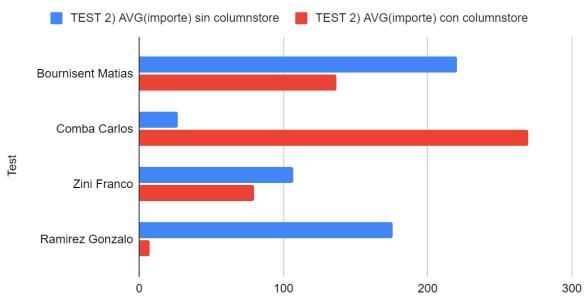
Test	Bournisent Matias	Comba Carlos	Zini Franco	Ramirez Gonzalo
TEST 1) SUM(importe) sin columnstore	220	43	107	177
TEST 1) SUM(importe) con columnstore	180	273	73	10
TEST 2) AVG(importe) sin columnstore	220	27	107	176
TEST 2) AVG(importe) con columnstore	137	270	80	7
TEST 3) COUNT(*) sin columnstore	93	27	50	83
TEST 3) COUNT(*) con columnstore	107	206	73	14
TEST 4) SELECT sin columnstore	6790	6750	5197	5956
TEST 4) SELECT con columnstore	6876	6730	2990	3537
TEST 5) SELECT/JOIN sin columnstore	2434	2254	1096	1890
TEST 5) SELECT/JOIN con columnstore	2616	2286	1014	1186
Cantidad de registros en las pruebas	1000000	1000000	1000795	1000000

Graficamos los tiempos para cada integrante en cada test

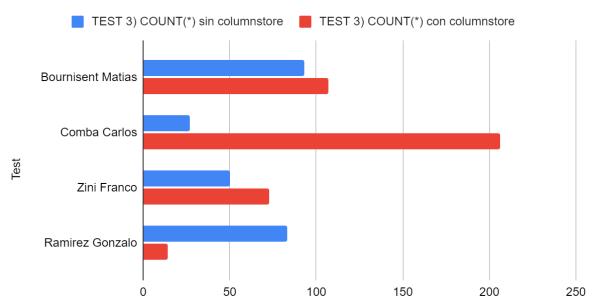
TEST 1) SUM(importe) sin columnstore y TEST 1) SUM(importe) con columnstore



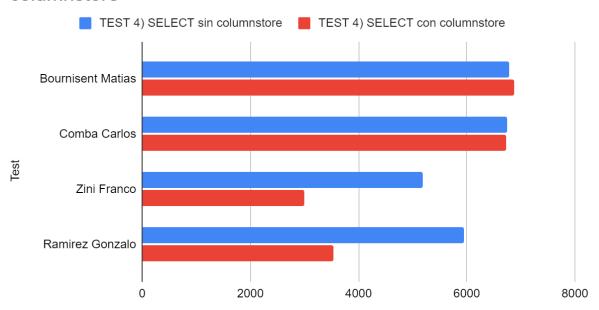
TEST 2) AVG(importe) sin columnstore y TEST 2) AVG(importe) con columnstore



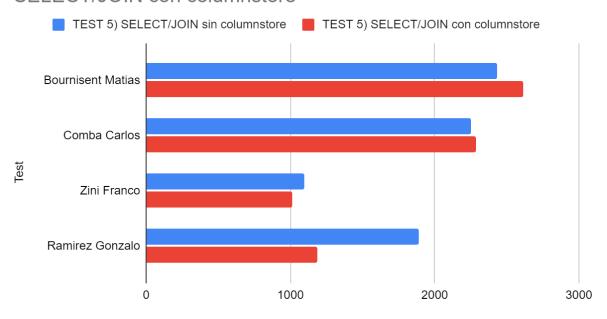
TEST 3) COUNT(*) sin columnstore y TEST 3) COUNT(*) con columnstore



TEST 4) SELECT sin columnstore y TEST 4) SELECT con columnstore



TEST 5) SELECT/JOIN sin columnstore y TEST 5) SELECT/JOIN con columnstore



Nuestros resultados muestran que la tabla con índice columnar, "gastonew", en la mayoría de los casos exhibe un mejor rendimiento en términos de tiempo de respuesta y costo en comparación con la tabla "gasto". En cada uno de los tests realizados, observamos tiempos de respuesta más rápidos y costos de consulta

sustancialmente menores en "gastonew". Estos resultados respaldan de manera concluyente la eficacia del índice columnar en la optimización del acceso a los datos. Sin embargo se observan dos casos en los cuales uno posee peor rendimiento con índice columnar, y otro en el que la mejora es sustancialmente mayor, atribuimos esto a diferencias en el hardware o configuración de cada entorno de ejecución.

Capítulo V: Conclusión

En conclusión, los índices columnares en SQL Server representan una herramienta fundamental para mejorar el rendimiento de las bases de datos. Esto se traduce en una mayor eficiencia operativa y en la capacidad de tomar decisiones más informadas. La implementación de índices columnares marca la diferencia en la experiencia de los usuarios y en el éxito de las aplicaciones y sistemas que dependen de una gestión eficaz de datos.

La estrategia de implementar índices columnares resulta ser de un valor incalculable para las organizaciones que buscan maximizar el valor de sus bases de datos. Al enfocarse en columnas específicas en lugar de en la tabla completa, los índices columnares permiten un acceso más rápido y eficiente a la información relevante. Como hemos demostrado en nuestras pruebas de rendimiento, la diferencia en tiempo y costo entre una columna con índice columnar y una columna sin él es sustancial, los índices columnares no solo aceleran las consultas, sino que también reducen los costos asociados con las operaciones de consulta, lo que tiene un impacto positivo en la eficiencia de la organización. En un mundo donde el acceso rápido y preciso a los datos es esencial, los índices columnares son una herramienta esencial.

Capítulo VI: Bibliografía

- 1. SQL Performance Explained" por Markus Winand
- Fundamentos de Base de Datos" de Korth H. y Silberschatz A. (1993, McGraw-Hill, ISBN: 84-481-0079-4)
- 3. Microsoft. (2023). Introducción a los índices de almacén de columnas.

 https://learn.microsoft.com/es-es/sql/relational-databases/indexes/columns

 tore-indexes-overview?view=sql-server-ver16
- blogvisionarios (2012). ColumnStore Index-Índices columnares en SQL https://blogvisionarios.com/articulos-data/columnstore-index-indices-columnares-en-sql/
- Redgate (2019). What are Columnstore Indexes?
 https://www.red-gate.com/simple-talk/databases/sql-server/t-sql-programmi
 nq-sql-server/what-are-columnstore-indexes/